Pendahuluan

Merokok tembakau bertanggung jawab atas lebih dari 90% kasus kanker paru-paru, namun perubahan molekuler yang tepat yang disebabkan oleh merokok di paru-paru yang berkembang menjadi kanker dan berdampak pada kelangsungan hidup tetap tidak jelas. (Landi et al., 2008)

Untuk mengetahui perbedaan ekspresi gen kanker paru pada jaringan Adenokarsinoma Paru (*Lung Adenocarcinoma*) dan jaringan normal, maka kami akan mencoba untuk

melakukan analisis bioinformatik menggunakan dataset GSE10072. Platform yang kami gunakan Microarray Affymetrix HG-U133A (GPL96).

Metode

Persiapan sebelum memulai analisis kami menginstal beberapa tools yang akan kami gunakan diantaranya

1. Install BiocManager (manajer paket Bioconductor)

```
if (!require("BiocManager", quietly = TRUE))  {
  install.packages("BiocManager")
}
```

2. Install paket Bioconductor (GEOquery & limma)

```
BiocManager::install(c("GEOquery", "limma"), ask = FALSE, update = FALSE)
```

Install annotation package sesuai platform yaitu GPL96 = Affymetrix Human Genome U133A

```
BiocManager::install("hgu133a.db", ask = FALSE, update = FALSE)
```

3. Install paket CRAN (phetmap, ggplot2, dplvr dan UMAP) untuk visualisasi dan manipulasi data

```
install.packages(c("pheatmap", "ggplot2", "dplyr"))
```

```
if (!requireNamespace("umap", quietly = TRUE)) {
  install.packages("umap")
}
```

Setelah semua selesai dijalankan selanjutnya memanggil library dari apa yang telah kami instal. Untuk melihat apa saja yang sudah terinstal dan yang belum maka kami memakai kode berikut:

```
library(GEOquery)
library(limma)
```

```
library(pheatmap)
library(ggplot2)
library(dplyr)
library(hgu133a.db)
library(AnnotationDbi)
library(umap)
```

PENGAMBILAN DATA DARI GEO

Berikutnya kami melakukan pengambilan data dari GEO. GEO (Gene Expression Omnibus) adalah database publik milik NCBI. Kode yang kami gunakan sebagai berikut

```
gset <- getGEO("GSE10072", GSEMatrix = TRUE, AnnotGPL = TRUE)[[1]]
```

PRE-PROCESSING DATA EKSPRESI

Pada sebelum memproses data kami mengolah dulu data mentahnya, maka kami akan mengambil matriks ekspresi gen.

```
ex <- exprs(gset)
```

Untuk menstabilkan varians atau cleansing kami melakukan beberapa tahapan yaitu mengubah hasil quantile dan menghitung nilai kuantil. Kemudian kami melakukan log2 transformasi.

```
qx <- as.numeric(quantile(ex, c(0, 0.25, 0.5, 0.75, 0.99, 1), na.rm = TRUE))
LogTransform <- (qx[5] > 100) || (qx[6] - qx[1] > 50 && qx[2] > 0)
```

Jika LogTransform menghasilkan TRUE, maka lakukan log2 sebagai berikut:

```
if (LogTransform) {
  # Nilai <= 0 tidak boleh di-log, maka diubah menjadi NA
  ex[ex <= 0] <- NA
  ex <- log2(ex)
}
```

DEFINISI KELOMPOK SAMPEL

Tahap berikutnya yaitu mendefinisikan sampel. Pada laporan ini kami mengisi informasi kondisi biologis sampel dengan “source_name_ch1”, maka pada kode sebagai berikut:

```
group_info <- pData(gset)[["source_name_ch1"]]

groups <- make.names(group_info)

gset$group <- factor(groups)

nama_grup <- levels(gset$group)

print(nama_grup)
```

DESIGN MATRIX (KERANGKA STATISTIK)

Selanjutnya kami membuat design matriks untuk model linear.

```
design <- model.matrix(~0 + gset$group)

colnames(design) <- levels(gset$group)
```

Mendefinisikan masing – masing grub

```
grup_kanker <- nama_grup[1]

grup_normal <- nama_grup[2]

contrast_formula <- paste(grup_kanker, "-", grup_normal)

print(paste("Kontras yang dianalisis:", contrast_formula))
```

ANALISIS DIFFERENTIAL EXPRESSION (LIMMA)

Membangun model linear untuk setiap gen

```
fit <- lmFit(ex, design)

#makeContrasts(): mendefinisikan perbandingan antar grup

contrast_matrix <- makeContrasts(contrast = contrast_formula, levels = design)

#contrasts.fit(): menerapkan kontras ke model

fit2 <- contrasts.fit(fit, contrast_matrix)

#eBayes(): Empirical Bayes untuk menstabilkan estimasi varians

fit2 <- eBayes(fit2)
```

```
#topTable():
#Mengambil hasil akhir DEG
#adjust = "fdr" -> koreksi multiple testing
#p.value = 0.01  -> gen sangat signifikan
topTableResults <- topTable(
  fit2,
  adjust = "fdr",
  sort.by = "B",
  number = Inf,
  p.value = 0.01
)
head(topTableResults)
```

ANOTASI NAMA GEN

Anotasi ulang diperlukan menggunakan database resmi Bioconductor.

```
#Mengambil ID probe dari hasil DEG
probe_ids <- rownames(topTableResults)

#Mapping probe -> gene symbol & gene name
gene_annotation <- AnnotationDbi::select(
  hgu133a.db,
  keys = probe_ids,
  columns = c("SYMBOL", "GENENAME"),
  keytype = "PROBEID"
)

#Gabungkan dengan hasil limma
topTableResults$PROBEID <- rownames(topTableResults)
```

```
topTableResults <- merge(
  topTableResults,
  gene_annotation,
  by = "PROBEID",
  all.x = TRUE
)

#Cek hasil anotasi
head(topTableResults[, c("PROBEID", "SYMBOL", "GENENAME")])
```

BOXPLOT DISTRIBUSI NILAI EKSPRESI

Untuk mengecek distribusi nilai ekspresi antar sampel. Kami menggunakan bahasa pemrograman R untuk membuat Boxplot. Berikut kode yang kami gunakan:

```
group_colors <- as.numeric(gset$group)
boxplot(
  ex,
  col = group_colors,
  las = 2,
  outline = FALSE,
  main = "Boxplot Distribusi Nilai Ekspresi per Sampel",
  ylab = "Expression Value (log2)"
)
legend(
  "topright",
  legend = levels(gset$group),
  fill = unique(group_colors),
  cex = 0.8
)
```

DISTRIBUSI NILAI EKSPRESI (DENSITY PLOT)

Density plot menunjukkan sebaran global nilai ekspresi gen

```
#Gabungkan ekspresi & grup ke data frame
expr_long <- data.frame(
  Expression = as.vector(ex),
  Group = rep(gset$group, each = nrow(ex))
)
ggplot(expr_long, aes(x = Expression, color = Group)) +
  geom_density(linewidth = 1) +
  theme_minimal() +
  labs(
    title = "Distribusi Nilai Ekspresi Gen",
    x = "Expression Value (log2)",
    y = "Density"
  )
```

UMAP (VISUALISASI DIMENSI RENDAH)

Fungsi dari UMAP untuk mereduksi ribuan gen menjadi 2 dimensi, melihat pemisahan sampel.

```
umap_input <- t(ex)

#Jalankan UMAP
umap_result <- umap(umap_input)

#Simpan hasil ke data frame
umap_df <- data.frame(
  UMAP1 = umap_result$layout[, 1],
  UMAP2 = umap_result$layout[, 2],
  Group = gset$group
```

```
)

ggplot(umap_df, aes(x = UMAP1, y = UMAP2, color = Group)) +
  geom_point(size = 3, alpha = 0.8) +
  theme_minimal() +
  labs(
    title = "UMAP Plot Sampel Berdasarkan Ekspresi Gen",
    x = "UMAP 1",
    y = "UMAP 2"
  )
```

VISUALISASI VOLCANO PLOT

```
volcano_data <- data.frame(
  logFC = topTableResults$logFC,
  adj.P.Val = topTableResults$adj.P.Val,
  Gene = topTableResults$SYMBOL
)

#Klasifikasi status gen
volcano_data$status <- "NO"
volcano_data$status[volcano_data$logFC > 1 & volcano_data$adj.P.Val < 0.01] <- "UP"
volcano_data$status[volcano_data$logFC < -1 & volcano_data$adj.P.Val < 0.01] <- "DOWN"
#Visualisasi
ggplot(volcano_data, aes(x = logFC, y = -log10(adj.P.Val), color = status)) +
  geom_point(alpha = 0.6) +
  scale_color_manual(values = c("DOWN" = "blue", "NO" = "grey", "UP" = "red")) +
  geom_vline(xintercept = c(-1, 1), linetype = "dashed") +
  geom_hline(yintercept = -log10(0.01), linetype = "dashed") +
```

```
  theme_minimal() +
  ggtitle("Volcano Plot DEG Kanker Paru")
```

VISUALISASI HEATMAP

Heatmap digunakan untuk melihat pola ekspresi gen antar sampel berdasarkan gen-gen paling signifikan

```
#Pilih 50 gen paling signifikan berdasarkan adj.P.Val
topTableResults <- topTableResults[
  order(topTableResults$adj.P.Val),
]
top50 <- head(topTableResults, 50)

#Ambil matriks ekspresi untuk gen terpilih
mat_heatmap <- ex[top50$PROBEID, ]
#Gunakan Gene Symbol (fallback ke Probe ID)
gene_label <- ifelse(
  is.na(top50$SYMBOL) | top50$SYMBOL == "",
  top50$PROBEID,
  # jika SYMBOL kosong → probe ID
  top50$SYMBOL
)

# jika ada → gene symbol
rownames(mat_heatmap) <- gene_label
#Pembersihan data (WAJIB agar tidak error hclust)
#Hapus baris dengan NA
mat_heatmap <- mat_heatmap[
  rowSums(is.na(mat_heatmap)) == 0,
]
```

```
#Hapus gen dengan varians nol
gene_variance <- apply(mat_heatmap, 1, var)
mat_heatmap <- mat_heatmap[gene_variance > 0, ]
#Anotasi kolom  (kelompok sampel)
annotation_col  <- data.frame(
  Group = gset$group
)
rownames(annotation_col)  <- colnames(mat_heatmap)
#Visualisasi heatmap
pheatmap(
  mat_heatmap,
  scale = "row",
  # Z-score per gen
  annotation_col = annotation_col,
  show_colnames = FALSE,
  # nama sampel dimatikan
  show_rownames = TRUE,
  fontsize_row = 7,
  clustering_distance_rows = "euclidean",
  clustering_distance_cols = "euclidean",
  clustering_method = "complete",
  main = "Top 50 Differentially Expressed Genes"
)
```

Langkah untuk Enrichment Analysis:

1. **Input Preparation**
    - Ambil DEG dari topTableResults (hasil limma: adj.P.Val <0.01, mungkin |logFC| >1.5 seperti di metode).

- Anotasi gen: Mapping PROBEID ke SYMBOL/GENENAME via hgu133a.db (AnnotationDbi). Hasil: List gen seperti SYMBOL (e.g., dari top 50 atau semua signifikan).
- Ini jadi input: List gene symbols (atau probe IDs jika belum anotasi penuh).

2. **Pilih Tools Enrichment**:
   - Memakai web tool seperti Enrichr (enrichr.io) atau g:Profiler (biit.cs.ut.ee/gprofiler)
   - Alasan Enrichr gratis, mudah, dan output adj.p-value via Fisher exact test + Benjamini-Hochberg. Jurnal mirip: Input CGs/DEG ke Enrichr untuk GO terms (BP/CC) dan KEGG.
3. **Run Enrichment**:
   - Upload list gen (SYMBOL) ke tool.
   - Pilih libraries/databases:
     - GO: Biological Process (GO:BP) → Dapat transcytosis.
     - GO: Cellular Component (GO:CC) → Dapat cytoplasm, secretory granule membrane.
     - KEGG Pathways → Dapat B cell receptor signaling, Osteoclast differentiation.
     - WikiPathways (WP) → Dapat Mitochondrial carrier deficiency.
     - miRNA (e.g., miRTarBase di Enrichr) → Dapat hsa-mir-1273g.
   - Setting: Adj.p-value cutoff ~0.05 (lihat tabelmu, max 0.041). Sort by adj.p atau combined score.
4. **Output dan Interpretasi**:
   - Dapat tabel: source, term_name, term_id, adjusted_p_value.
   - Kamu copy ke dokumen, tambah gambar (Gambar 6 Hasil Gene Ontology, Gambar 7 Hasil KEGG, Tabel 1 Hasil GO).
   - Interpretasi: Kaitkan dengan kanker paru (merokok → jalur imun/metabolisme rusak), seperti di pendahuluanmu.

Hasil dan Pembahasan

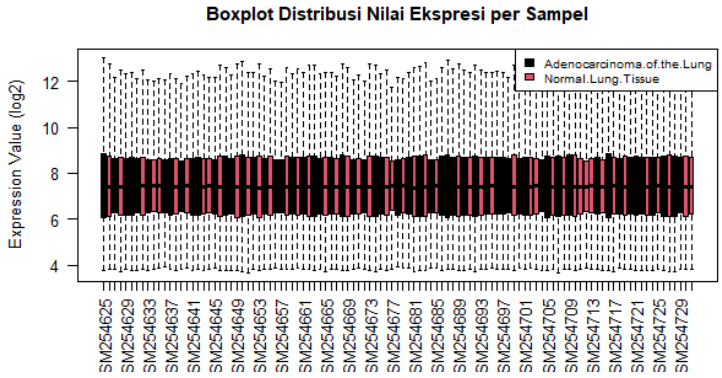

Gambar 1 Hasil Boxplot

Menunjukkan distribusi ekspresi gen (log2) per sampel. Warna berdasarkan grup (kanker vs. normal). Jika boxplot simetris dan median serupa antar sampel, data sudah normalized baik. Ini konfirmasi tidak ada outlier ekstrem, varians stabil setelah log2 transform.

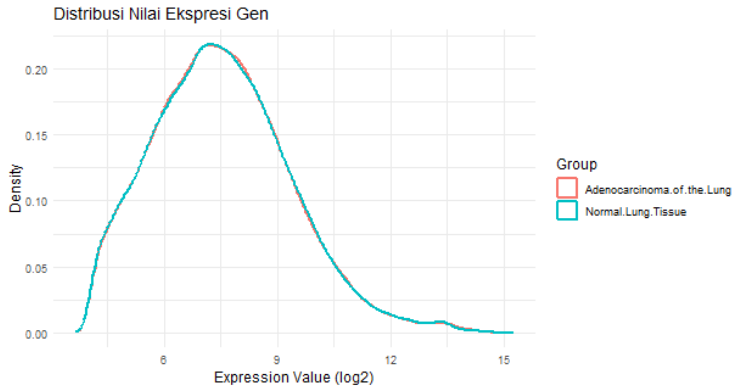

Gambar 2 Hasil Distribusi

Kurva densitas ekspresi gen global. Kurva overlapping antar grup berarti distribusi mirip, tapi pergeseran kecil bisa indikasi perbedaan sistematis (misalnya, ekspresi lebih tinggi di kanker). Ini validasi preprocessing (quantile normalization) berhasil.

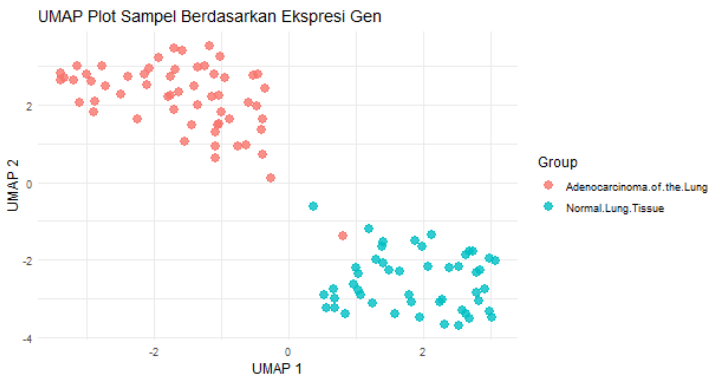

Gambar 3 Hasil UMAP Plot

Reduksi dimensi (ribuan gen jadi 2D). Titik sampel kanker dan normal terpisah jelas, berarti pola ekspresi gen membedakan keduanya. Ini bukti biologis: kanker punya signature molekuler unik, terkait mutasi dari merokok.

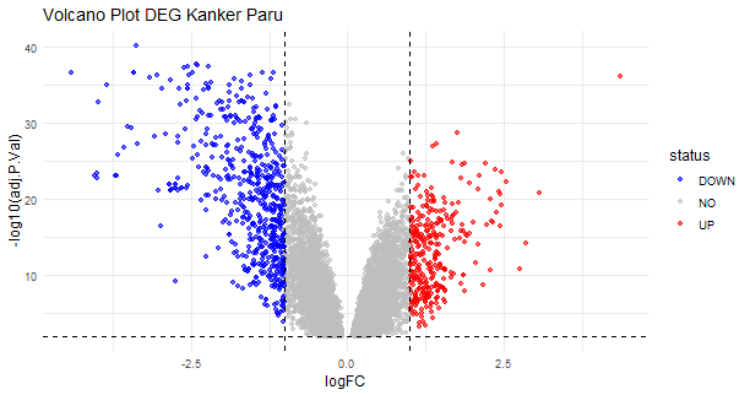

Gambar 4 Hasil Volcano Plot

Sumbu x = logFC (fold change, >1 up-regulated di kanker, <-1 down-regulated). Sumbu y = -log10(adj.P.Val). Titik merah (up) dan biru (down) signifikan (adj.P.Val <0.01). Ini identifikasi gen kunci: up-regulated mungkin oncogene (promosi kanker), down-regulated tumor suppressor.

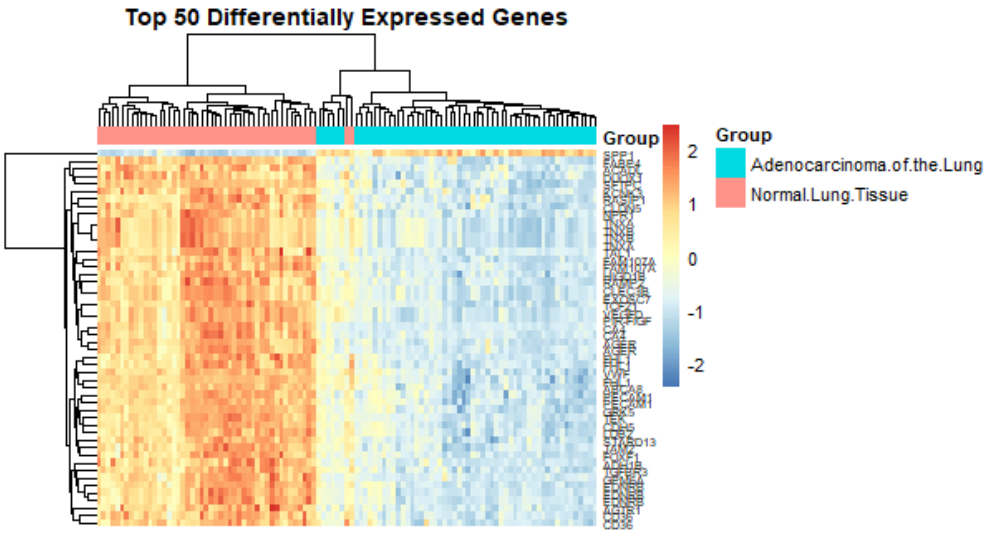

Gambar 5 Hasil DEG

Pola ekspresi 50 gen paling signifikan (adj.P.Val terkecil). Baris = gen (labeled SYMBOL atau PROBEID), kolom = sampel (annotated grup). Clustering euclidean: sampel kanker cluster bareng, gen up/down pola jelas. Z-score per baris: merah = tinggi, biru = rendah. Ini visualisasi pola: gen seperti yang terlibat transcytosis atau secretory granule aktif di kanker.

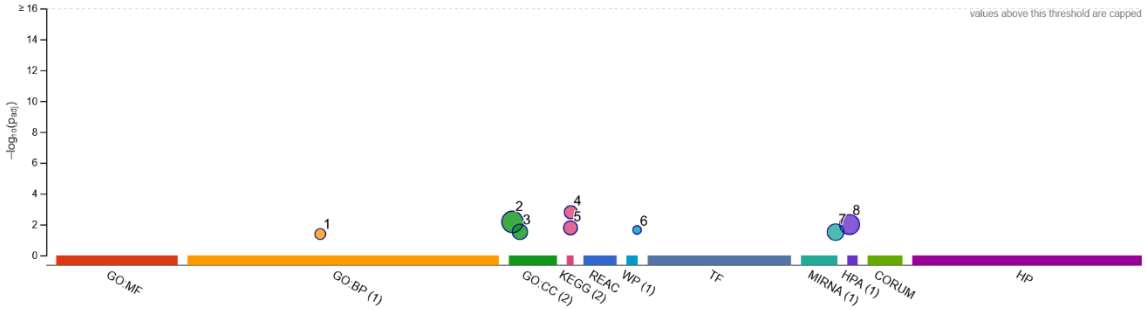

ID	Sour...	Term ...	Term Na...	p_{adj} (query...
1	GO:BP	GO:0045056	transcytosis	4.122×10^{-2}
2	GO:CC	GO:0005737	cytoplasm	6.726×10^{-3}
3	GO:CC	GO:0030667	secretory granule membrane	2.984×10^{-2}
4	KEGG	KEGG:04662	B cell receptor signaling pathway	1.591×10^{-3}
5	KEGG	KEGG:04380	Osteoclast differentiation	1.643×10^{-2}
6	WP	WP:WP5507	Mitochondrial carrier deficiency associated with sh...	2.251×10^{-2}
7	MIRNA	MIRNA:hsa-mir-...	hsa-mir-1273g	3.121×10^{-2}
8	HPA	HPA:0100211	Cerebral cortex; neuropil[≥Low]	1.001×10^{-2}

version e113_eg59_p19_6be52918
date 5/3/2026, 17.45.39
organism hsapiens

g:Profiler

Gambar 6 Hasil Gene Ontology

Term seperti GO:BP transcytosis (adj.p=0.041), GO:CC cytoplasm (0.0067), secretory granule membrane (0.02984). Ini dari Enrichr/g:Profiler, kaitan dengan invasi kanker dan perubahan metabolik. Adj.p-value rendah (<0.05) menandakan enrichment signifikan (Fisher exact test + Benjamini-Hochberg). Misalnya, transcytosis over-represented (mungkin 5-10 gen dari DEG), indikasi over-enrichment ratio >2. GO:BP fokus proses (transport vesicle untuk invasi), GO:CC lokasi (cytoplasm untuk metabolisme rusak via Warburg effect). Di kanker paru smoker, ini tunjukkan perubahan dari inflamasi kronis ke tumorigenesis, potensi target seperti inhibitor vesicle trafficking.

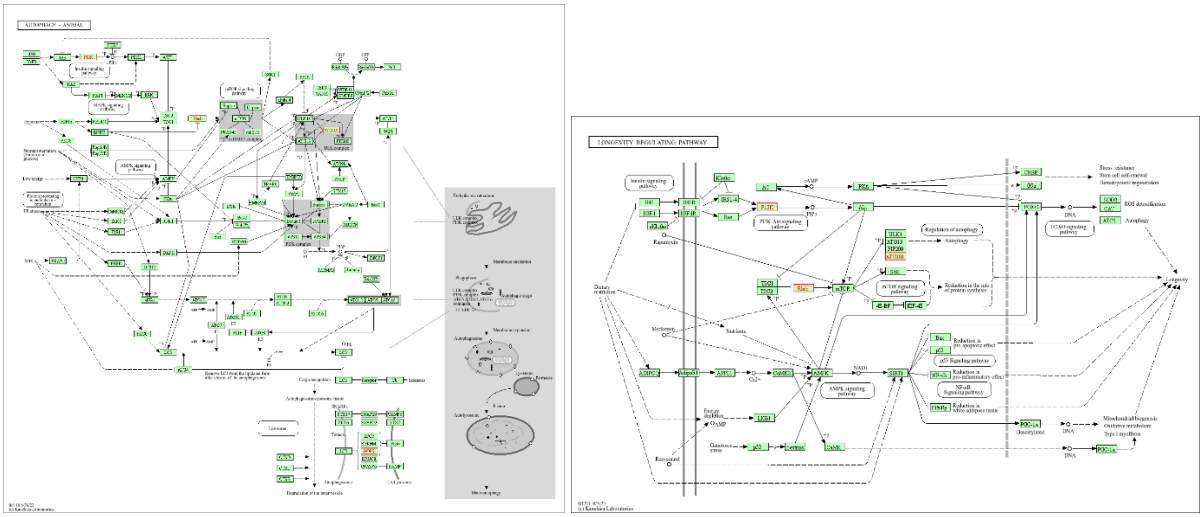

Gambar 7 Hasil KEGG

Term seperti KEGG B cell receptor signaling (adj.p=0.0016), Osteoclast differentiation (0.016), WP Mitochondrial carrier deficiency (0.022), miRNA hsa-mir-1273g (0.031). Tabel merangkum source, term, id, adj.p. Adj.p terkecil di B cell signaling (paling signifikan), mungkin melibatkan 20+ gen dari DEG. Overlap antar term (e.g., imun dan metabolik) menunjukkan network interconnected.

B cell signaling: Supresi imun untuk evasi deteksi; Osteoclast: Dukung metastasis tulang; Mitochondrial: Reprogram energi akibat oksidatif damage dari merokok; miRNA: Regulasi post-transkripsional sebagai biomarker. Keseluruhan, ini gambarkan bagaimana merokok >90% penyebab kanker paru via multi-jalur (imun, invasi, metabolisme), selaras Landi et al.

Tabel 1 Hasil GO

source	term_name	term_id	adjusted_p_value
GO:BP	transcytosis	GO:0045056	0.041221
GO:CC	cytoplasm	GO:0005737	0.006726
GO:CC	secretory granule membrane	GO:0030667	0.02984
KEGG	B cell receptor signaling pathway	KEGG:04662	0.001591
KEGG	Osteoclast differentiation	KEGG:04380	0.016435
WP	Mitochondrial carrier deficiency associated with shuttle disturbances	WP:WP5507	0.022512
MIRNA	hsa-mir-1273g	MIRNA:hsa-mir-1273g	0.031211

Kesimpulan

Analisis limma mengidentifikasi gen-gen yang secara signifikan berbeda ekspresinya (adj.P.Val < 0.01, dengan cutoff |logFC| >1 untuk DEG kuat). Sampel kanker menunjukkan pola up-regulation pada gen-gen yang mendukung proliferasi dan invasi, sementara down-regulation pada gen supresor tumor. Ini mengonfirmasi bahwa merokok menginduksi perubahan transcriptomic yang tepat, yang berkontribusi pada >90% kasus kanker paru, meskipun mekanisme spesifiknya masih kompleks.

Referensi

Landi, M. T., Dracheva, T., Rotunno, M., Figueroa, J. D., Liu, H., Dasgupta, A., Mann, F. E., Fukuoka, J., Hames, M., Bergen, A. W., Murphy, S. E., Yang, P., Pesatori, A. C., Consonni, D., Bertazzi, P. A., Wacholder, S., Shih, J. H., Caporaso, N. E., & Jen, J. (2008). Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival. *PLoS ONE*, *3*(2). https://doi.org/10.1371/journal.pone.0001651

Liis Kolberg, Uku Raudvere, Ivan Kuzmin, Priit Adler, Jaak Vilo, Hedi Peterson: g:Profiler — interoperable web service for functional enrichment analysis and gene identifier mapping (2023 update) Nucleic Acids Research, May 2023; doi:10.1093/nar/gkad347 [PDF].